



Análisis de Fuentes de Datos y Big Data



Caso de estudio

Sistema de ventas de una tienda en línea

Este proyecto analiza las principales fuentes de datos generadas por una tienda en línea, clasificándolas según su estructura y evaluando las **5 V del Big Data**: volumen, velocidad, variedad, veracidad y valor.

1. Fuentes de datos

El sistema de comercio electrónico obtiene información de diferentes fuentes relacionadas con las ventas, pagos, inventario y comportamiento de los clientes.

#	Fuente de datos	Ejemplos	Tipo
1	Base de datos de ventas	ID del pedido, producto, cantidad, precio y fecha	● Estructurado
2	Sistema de inventario	Existencias, entradas y salidas	● Estructurado
3	Registros de pagos	Pagos aprobados, rechazados y reembolsos	● Estructurado
4	Registros de navegación web	Clics, páginas visitadas y sesiones	● Semiestructurado
5	Logs del servidor	Errores, tiempos de respuesta y actividad	● Semiestructurado
6	Reseñas de clientes	Opiniones, quejas y sugerencias	● No estructurado
7	Imágenes de productos	Fotografías y material promocional	● No estructurado
8	Correos de atención al cliente	Consultas, reclamos y solicitudes	● No estructurado

Clasificación

- **Estructurado**: datos organizados mediante un esquema definido, normalmente en tablas.
- **Semiestructurado**: datos que poseen cierta organización, pero no siguen necesariamente una estructura tabular fija.
- **No estructurado**: información que no posee una estructura de datos definida, como textos, imágenes y correos.

2. Las 5 V del Big Data

Las cinco dimensiones analizadas son **volumen, velocidad, variedad, veracidad y valor**.

V	Importancia	Justificación
Volumen	● Alta	La tienda puede generar millones de registros de ventas, visitas, pagos y actividades de los usuarios.
Velocidad	● Alta	Las compras, pagos e inventario deben actualizarse rápidamente para mantener la información actualizada.
Variedad	● Alta	Se manejan diferentes formatos, como tablas, logs, textos, correos electrónicos e imágenes.
Veracidad	● Muy alta	Los datos incorrectos pueden generar errores en pagos, inventario y toma de decisiones.
Valor	● Alta	Los datos permiten obtener información útil para analizar ventas, conocer a los clientes y mejorar el negocio.

★ V más críticas

Para este caso, las dimensiones más críticas son:

1. **Veracidad:** los datos deben ser correctos y confiables para evitar errores.
2. **Velocidad:** la información debe procesarse rápidamente, especialmente en pagos y actualización del inventario.
3. **Variedad:** el sistema recibe información de múltiples fuentes y en diferentes formatos.

3. ⚠ Problema de veracidad

Problema identificado

Un posible problema de calidad es que el **inventario registrado en el sistema no coincida con la cantidad real de productos disponibles**.

Por ejemplo:

```

Inventario del sistema: 10 unidades
Inventario físico:      5 unidades
Diferencia:             5 unidades

```

Esto puede ocurrir debido a:

- Retrasos en la actualización del inventario.
- Registros duplicados.
- Errores durante las transacciones.
- Fallos en la sincronización entre sistemas.

¿Cómo detectarlo?

El problema podría detectarse mediante:

- Comparaciones periódicas entre el inventario físico y el digital.
 - Detección de registros duplicados.
 - Validación de cantidades negativas o fuera de rango.
 - Comparación entre las ventas realizadas y las existencias.
 - Alertas ante cambios inusuales en el inventario.
-

4. Reto de calidad de datos

El principal reto es mantener la **consistencia, exactitud y actualización de los datos de inventario**.

Esto es especialmente importante cuando se producen muchas compras simultáneamente, ya que un retraso o error en la actualización puede generar información incorrecta y afectar directamente al cliente y al negocio.

5. Conclusión

El sistema de ventas de una tienda en línea genera información a partir de diferentes fuentes y formatos. Por esta razón, es necesario identificar y clasificar correctamente los datos.

Las dimensiones más importantes para este caso son **veracidad, velocidad y variedad**, debido a que el negocio necesita información confiable, actualizada y proveniente de diferentes fuentes.

Una adecuada gestión de la calidad de los datos permite reducir errores, mejorar la experiencia del cliente y facilitar la toma de decisiones basada en información confiable.

Tecnologías / Conceptos

- Big Data
 - Fuentes de datos
 - Datos estructurados
 - Datos semiestructurados
 - Datos no estructurados
 - Las 5 V del Big Data
 - Calidad y veracidad de datos
-

Actividad académica — Análisis de Big Data