



Arquitectura de Datos - Tienda en Línea




Descripción

En este documento se presenta una propuesta de arquitectura de datos para un sistema de ventas de una tienda en línea.

La arquitectura permite recopilar información desde diferentes fuentes, procesarla y transformarla en información útil para el análisis y la toma de decisiones.

1. Diagrama de arquitectura



Flujo general

Fuentes → Ingesta → Almacenamiento → Procesamiento → Análisis / BI

2. 📊 Elección: Data Lake o Data Warehouse

✅ Decisión: Data Lake

Se selecciona un **Data Lake** como solución principal de almacenamiento.

La tienda en línea genera diferentes tipos de datos:

- **Datos estructurados:** ventas, pagos e inventario.
- **Datos semiestructurados:** logs y registros de navegación.
- **Datos no estructurados:** reseñas, correos e imágenes.

El Data Lake permite almacenar estos datos en diferentes formatos y conservarlos en su forma original para procesarlos posteriormente.

¿Por qué no utilizar únicamente un Data Warehouse?

Un **Data Warehouse** es una buena opción para datos estructurados y reportes empresariales. Sin embargo, en este caso también se necesitan almacenar datos semiestructurados y no estructurados.

Por esta razón, el **Data Lake ofrece mayor flexibilidad** para este escenario.

Decisión: utilizar un **Data Lake** debido a la variedad de fuentes y formatos de datos.

3. ⚡ Elección: Batch o Streaming

✅ Decisión: Streaming + Batch

Se propone utilizar una combinación de **Streaming y Batch**, ya que el sistema tiene necesidades tanto de tiempo real como de procesamiento histórico.

⚡ Streaming

El procesamiento en tiempo real se utilizará principalmente para:

- 🛒 Compras.
- 💳 Pagos.
- 📦 Actualización del inventario.
- 👤 Navegación de los usuarios.
- 👤 Actividad en la plataforma.


El Streaming permite que estos datos sean procesados rápidamente y que la información se mantenga actualizada.

Batch

El procesamiento por lotes se utilizará para actividades que no necesitan resultados inmediatos, como:

- Reportes diarios de ventas.
- Análisis históricos.
- Informes mensuales.
- Procesamiento de grandes cantidades de datos acumulados.

Flujo





Decisión: combinar **Streaming y Batch** para cubrir tanto las necesidades de información en tiempo real como los análisis históricos.

4. Herramientas propuestas

Etap	Herramienta	Justificación
Ingesta	Apache Kafka	Permite recibir y distribuir grandes cantidades de eventos en tiempo real.
Almacenamiento	Data Lake	Permite almacenar datos estructurados, semiestructurados y no estructurados.
Procesamiento	Apache Spark	Permite limpiar, transformar y procesar grandes volúmenes de datos.
Análisis / BI	Power BI	Permite crear dashboards, gráficos e informes para facilitar la toma de decisiones.

5. Arquitectura tecnológica





6. 📋 Resumen de decisiones

Aspecto	Selección	Motivo
Almacenamiento	Data Lake	Permite trabajar con diferentes tipos y formatos de datos.
Ingesta	Streaming	Permite recibir y procesar información rápidamente.
Procesamiento	Apache Spark	Adecuado para grandes volúmenes de datos.
Procesamiento histórico	Batch	Ideal para reportes y análisis periódicos.
Business Intelligence	Power BI	Facilita la visualización y análisis de los resultados.

7. Conclusión

La arquitectura propuesta permite transformar los datos generados por la tienda en línea en información útil para el negocio.

Se selecciona un **Data Lake** debido a la variedad de datos generados por las diferentes fuentes.

Para el procesamiento se propone combinar **Streaming y Batch**. Streaming permite atender eventos que requieren una respuesta rápida, como compras, pagos e inventario, mientras que Batch permite realizar análisis históricos y generar reportes periódicos.

Las herramientas propuestas son:

- **Apache Kafka:** ingesta de datos.
- **Data Lake:** almacenamiento.
- **Apache Spark:** procesamiento.
- **Power BI:** análisis y visualización.

Esta arquitectura proporciona una solución flexible y escalable para gestionar los datos de una tienda en línea.